



ANÁLISIS EXPLORATORIO

Datos clínicos relacionados con infección

De las distribuciones individuales a una visión multivariada de los pacientes.

Analisis Multivariado · Matemáticas Aplicadas

Basado en TareaPráctica1.ipynb

Integrantes:

- Galan Resendiz Andres Roberto
- Olivares Hernandez Argenis Daniel
- Ramos Reyes Paulina

¿Qué queremos entender?

La idea es seguir una pregunta a la siguiente..

01	Infección	¿Qué características de los pacientes se relacionan con la infección?
02	Comportamiento conjunto	¿Cómo se comportan variables clínicas, demográficas y de tratamiento?
03	CD4 en el tiempo	¿Los pacientes que comienzan con CD4 altos los conservan?
04	Edad y CD4	¿La edad tiene una relación visible con CD4?
05	Peso y CD4	¿El peso influye en los patrones de las células CD4?

calidad → distribución → CD4/CD8 → correlaciones → multivariado → preguntas nuevas

Ruta del análisis

1. Primero: conocer los datos

Antes de buscar patrones, revisamos si la base es consistente.

2139

pacientes /
observaciones

23

variables

0

valores faltantes

0

filas duplicadas

Idea clave

La base permite concentrarnos en las relaciones, sin tener que corregir datos faltantes o duplicados.

Variables que guían la historia


- Demográficas: edad y peso.
- Clínicas: CD4, CD8, síntomas, estado funcional, entre otras.
- Tratamiento: tratamiento previo, tratamiento y suspensión.
- Respuesta: infected.

Un detalle que ya llama la atención

Los conteos de CD4 y, sobre todo, CD8 tienen una dispersión mucho mayor que edad y peso. Eso sugiere que el comportamiento inmunológico merece ser el centro del análisis.

2. El punto de partida: la variable de infección

La clase 0 es claramente mayoritaria; esto importa al comparar grupos.



Primera observación

La distribución de infected no es balanceada. La clase 0 contiene muchas más observaciones que la clase 1.

¿Por qué importa?


Una diferencia visual entre grupos puede amplificarse simplemente porque uno de ellos es mucho más grande. Por eso conviene mirar distribuciones y proporciones, no solo conteos.

Siguiente pregunta

¿Qué variables sí muestran un patrón diferente entre ambas clases?

3. El CD4 aparece como la primera pista fuerte

Comparamos CD4 inicial y CD4 después de 20 semanas, separados por infección.



Patrón

La clase 1 se concentra más hacia valores bajos de CD4.

En ambos momentos aparece el mismo orden general, aunque existe bastante traslape entre las distribuciones.

Esto sugiere asociación, no una regla determinista.

Pregunta que se abre:

¿Los pacientes que empiezan con CD4 altos logran conservar esa ventaja?

4. CD4: hay persistencia, pero no es perfecta

Los promedios suben, pero la correlación muestra que hay variación individual.

350.50 → 371.31

media CD4 inicial → posterior

+20.81

cambio promedio

0.58

correlación CD4 inicial /
posterior

Lectura

Un CD4 inicial alto aporta información sobre el CD4 posterior, pero no determina el resultado individual.

Interpretación

- Existe una tendencia de conservación: pacientes con CD4 inicial alto tienden a permanecer relativamente altos.
- El aumento de la media no implica que todos los pacientes mejoren.
- La correlación de 0.58 es moderada: otros factores todavía pueden explicar parte importante del cambio.

Una variable nueva sería útil


En vez de mirar solo el nivel posterior, podemos estudiar el cambio individual:

$$\Delta\text{CD4} = \text{CD4 posterior} - \text{CD4 inicial}$$

Eso permitiría preguntar qué características explican quién mejora y quién disminuye.

5. CD8 cuenta una historia distinta

Aquí la estabilidad temporal es mayor y aparecen muchos valores extremos.



0.76

correlación CD8 inicial / posterior

0.58

correlación CD4 inicial / posterior

Lo inesperado


CD8 parece conservar más su estructura en el tiempo que CD4.

Observación que merece atención

Los valores máximos son muy altos y generan muchos outliers. Antes de eliminarlos habría que saber si son errores o pacientes realmente atípicos.

6. La matriz de correlaciones ordena las pistas

Nos ayuda a distinguir relaciones fuertes de coincidencias débiles.



Las relaciones más claras

0.76 CD8 inicial ↔ CD8 posterior

0.58 CD4 inicial ↔ CD4 posterior

0.13 Edad ↔ peso

0.04 / -0.04 Peso/edad ↔ CD4

Edad y peso no muestran una relación lineal importante con CD4.

7. Edad y peso: una ausencia también es un resultado

No todo patrón esperado aparece en los datos.

Edad ↔ CD4

$$r \approx -0.04$$

No se observa una relación lineal importante entre edad y CD4, ni inicial ni posterior.

Peso ↔ CD4

$$r \approx 0.02-0.04$$


El peso tampoco muestra una relación lineal relevante con los niveles de CD4.

Pero “correlación ≈ 0 ” no significa “ninguna relación posible”.

- Podría existir una relación no lineal que la correlación no detecta.
- También puede existir una relación mediada por otras variables clínicas o de tratamiento.
- La siguiente exploración natural sería usar cambios de CD4 y separar por grupos de edad o peso.

8. Cuando juntamos las variables, el panorama se complica

Una persona no está definida por una sola variable.



¿Qué vemos?


- Las trayectorias de las clases están muy mezcladas.
- No aparece una combinación simple de edad, peso, CD4 y CD8 que separe perfectamente los grupos.
- La variabilidad dentro de cada clase también es grande.

Consecuencia

La infección parece estar asociada con un patrón multivariado, no con una sola característica aislada.


9. Otras vistas multivariadas confirman el traslape

Andrews y t-SNE son útiles para explorar estructura, pero no para “probar” causalidad.



Andrews

Las curvas de ambas clases se superponen bastante: hay estructura, pero no separación limpia.



t-SNE

Hay agrupaciones locales, pero dentro de ellas aparecen puntos de ambas clases.

10. El análisis abre nuevas preguntas

Aquí es donde la exploración deja de ser una lista de gráficas y se convierte en investigación.

Δ CD4

¿Qué explica que algunos pacientes mejoren y otros disminuyan?

Tratamiento

¿El tratamiento está asociado con cambios distintos en CD4?

CD4/CD8

¿La razón CD4/CD8 muestra un patrón más claro que cada conteo por separado?

Outliers

¿Los valores extremos de CD8 representan errores o pacientes particulares?

No linealidad

¿Edad y peso esconden relaciones no lineales con CD4?

11. Conclusiones

La historia que dejan los datos es más interesante que una sola gráfica.

CD4 y CD8 son las variables que mejor conectan los momentos inicial y posterior.

- La clase 1 muestra mayor concentración de pacientes con CD4 bajo, tanto al inicio como a las 20 semanas.
- CD4 presenta persistencia moderada ($r = 0.58$); CD8 presenta una persistencia mayor ($r = 0.76$).
- Edad y peso tienen correlaciones prácticamente nulas con CD4 en este conjunto de datos.
- Las herramientas multivariadas muestran bastante traslape: no existe una separación simple entre las clases.
- Los outliers de CD8 y el cambio individual de CD4 son puntos que merecen una exploración posterior.

Idea final

La exploración no termina al encontrar una correlación: termina cuando una observación lleva a una pregunta mejor.

GRACIAS

Con esto concluimos

Análisis exploratorio de datos clínicos

Basado en TareaPráctica1.ipynb

UNAM · Matemáticas Aplicadas